

# 多元统计分析—R 与 Python 的实现

## 矩阵代数回顾

吴喜之

June 26, 2019

**矩阵定义** 矩阵是数值或数值变量的一个矩形数字阵,  $m$  行  $n$  列 (亦称  $m \times n$  维或  $m \times n$  阶) 的矩阵  $A$  的形式为:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}.$$

一些矩阵形式:

- 对称矩阵
- 上三角矩阵, 下三角矩阵, 单位矩阵, 矩阵的转置

# 矩阵基本运算和概念:

- 加、减、乘
- 行列式计算
- 矩阵的逆及广义逆
- 矩阵 Kronecker 乘积
- 幂等矩阵
- 向量空间
- 矩阵的秩
- 矩阵的迹
- 矩阵的特征值及广义特征值
- 分块矩阵

## 矩阵的分解: 特征值分解

特征值分解 (eigenvalue decomposition) 也称为谱分解 (spectral decomposition) 为从空间  $\mathbb{R}^p$  到其本身通过  $p \times p$  方阵  $A$  的映射,  $A : \mathbb{R}^p \mapsto \mathbb{R}^p$ . 如果秩为  $r$  的矩阵  $A$  的非零特征值和相应的特征向量矩阵分别为  $\lambda_1, \lambda_2, \dots, \lambda_r$  和  $\Gamma = [\gamma_1, \gamma_2, \dots, \gamma_r]$ , 则有

$$A\Gamma = \Gamma\Lambda,$$

这里,  $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_r)$ . 如果  $A$  满秩, 则有特征值分解

$$A = \Gamma\Lambda\Gamma^{-1}.$$

## 矩阵的分解: 奇异值分解

奇异值分解 (singular value decomposition, SVD) 是上述特征值分解的推广: 每个具有秩  $r$  的矩阵  $A(n \times p)$  能够分解成

$$A = U \Sigma V^H, \quad (0.1)$$

这里矩阵  $U_{n \times n}$  和  $V_{p \times p}$  都是酉矩阵 (对于复数矩阵  $A$ )<sup>1</sup> 或列正交 (对于实矩阵  $A$ ) 的. 矩阵  $\Sigma$  为非负实元素组成的  $n \times p$  对角矩阵. 矩阵  $\Sigma$  的非零对角线元素称为  $A$  的非零奇异值, 这些奇异值为  $AA^H$  和  $A^H A$  的共同非零特征值的平方根.<sup>2</sup>

<sup>1</sup>矩阵  $U$  为酉矩阵 (unitary matrix, 也称么矩阵) 的条件是其共轭转置 (亦称 Hermitian 转置)  $U^H$  是其逆矩阵, 即  $U^H U = U U^H = I$ .

<sup>2</sup>矩阵  $AA^H$  和  $A^H A$  的正交特征向量分别称为  $A$  的左奇异向量 (left-singular vectors) 和右奇异向量 (right-singular vectors).

## 矩阵的分解: 广义奇异值分解

下面的广义奇异值分解 (generalized singular value decomposition, GSVD) 是前面奇异值分解的带约束的推广. 假定矩阵  $A_{n \times p}$  的奇异值分解为:

$$A = U D V^H,$$

这里的约束为

$$U^H W_u U = V^H W_v V = I.$$

这意味着, 给定约束  $W_u$  和  $W_v$ , 矩阵  $U$  和  $V$  为正交的.  $W_u$  和  $W_v$  往往为正定的, 甚至是正定对角矩阵.

### 广义奇异值分解 (定义 2)

还有一种广义奇异值分解: 对于  $m \times n$  矩阵  $A$  和  $p \times n$  矩阵  $B$ , 它们的广义奇异值分解由下面一对因子化定义:

$$A = U \Sigma_1 [0, R] Q^\top;$$

$$B = V \Sigma_2 [0, R] Q^\top.$$

## 矩阵的分解: QR 分解

一个  $n \times n$  实方阵  $A$  可以分解为

$$A = QR,$$

这里的  $Q$  是一个  $n \times n$  正交矩阵, 即  $Q^T Q = I$ , 而  $R$  是一个  $n \times n$  上三角矩阵. 如果  $A$  可逆, 则该分解是唯一的. 如果矩阵  $A$  的列线性独立, 则  $Q$  的列形成  $A$  的列空间的正交基. 对于复数矩阵, 上述分解中的  $Q$  为酉矩阵, 即  $Q^H Q = I$ , 其中  $Q^H$  为  $Q$  的共轭转置.

## 矩阵的分解: Cholesky 分解

如果  $A$  为实质对称正定矩阵, Cholesky 分解为:

$$A = LL^{\top},$$

这里的  $L$  是一个下三角矩阵. 如果  $A$  为更一般的 Hermitian 正定矩阵, Cholesky 分解为:

$$A = LL^H.$$

这里  $L$  是一个下三角矩阵, 而  $L^H$  是  $L$  的共轭转置矩阵, 对于实对称正定矩阵 (及更一般的 Hermitian 正定矩阵), 都有唯一的 Cholesky 分解.



## 二次型: 定义

二次型  $Q(\mathbf{x})$  是一个  $\mathbb{R}^p \mapsto \mathbb{R}$  的投影, 由对称矩阵  $\mathbf{A}_{p \times p} = \{a_{ij}\}$  ( $a_{ij} = a_{ji}$ ) 和向量  $\mathbf{x} = (x_1, x_2, \dots, x_p) \in \mathbb{R}^p$  组成:

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \sum_{i=1}^p \sum_{j=1}^p a_{ij} x_i x_j.$$

二次型具有唯一性, 如果对于对称的  $\mathbf{A}$  和  $\mathbf{B}$ ,  
 $\mathbf{x}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{B} \mathbf{x}, \forall \mathbf{x} \in \mathbb{R}^p$ , 那么  $\mathbf{A} = \mathbf{B}$ .

对于常数  $a$ , 满足  $Q(\mathbf{x}) = a$  的  $\mathbf{x}$  (记为  $\{\mathbf{x} | Q(\mathbf{x}) = a\}$ ) 形成的曲面称为二次曲面, 而  $\{\mathbf{x} | Q(\mathbf{x}) \leq a\}$  称为二次区域.

## 二次型: 矩阵的定性

考虑对称矩阵  $A \in \mathbb{R}^{p \times p}$ . 如果  $Q(x) > 0, \forall x \neq 0$ , 称  $A$  为正定的, 并记为  $A > 0$ .  $A > 0$  的充分必要条件为其最小特征值大于零. 如果  $Q(x) \geq 0, \forall x \neq 0$ , 称  $A$  为半正定的, 并记为  $A \geq 0$ .  $A \geq 0$  的充分必要条件为其特征值均为非负. 类似地, 可以定义负定和半负定.

## 二次型: 距离

令  $x, y \in \mathbb{R}^p$ , 而  $x$  和  $y$  之间的距离定义为下面的函数  $d$ .

$$d: \mathbb{R}^{2p} \mapsto \mathbb{R}_+ \text{ 满足 } \begin{cases} d(x, y) > 0, & \forall x \neq y; \\ d(x, y) = 0, & \text{当且仅当 } x = y; \\ d(x, y) \leq d(x, z) + d(z, y), & \forall x, y, z (z \in \mathbb{R}^p). \end{cases}$$

$x$  和  $y$  之间的欧式距离  $d$  定义为:

$$d^2(x, y) = (x - y)^\top A(x - y),$$

这里的  $A$  为正定矩阵 ( $A > 0$ ).  $A$  称为一个度量, 特例为  $A = I_p$ .

## 二次型: 椭球

集合  $E_d = \{x \in \mathbb{R}^p | (x - x_0)^\top (x - x_0) = d^2\}$ , 即以  $x_0$  为中心、 $d$  为半径的球面.  
更一般的情况为:

$$E_d = \{x \in \mathbb{R}^p | (x - x_0)^\top A (x - x_0) = d^2\}.$$

它是以  $x_0$  为中心的椭球面. 如果这一等式中的等号改成小于等于号 ( $\leq d^2$ ), 则为以  $x_0$  为中心的椭球.

令  $\gamma_1, \gamma_2, \dots, \gamma_p$  为  $A$  的相应于特征值  $\lambda_1, \lambda_2, \dots, \lambda_p$  的正交特征向量, 有

- ❶  $E_d$  的主轴方向为  $\gamma_i, i = 1, 2, \dots, p$ ;
- ❷ 半轴长度为  $\sqrt{d^2/\lambda_i}, i = 1, 2, \dots, p$ ;
- ❸ 围绕  $E_d$  的矩形由下列不等式定义:

$$x_{0i} - \sqrt{d^2 a^{ii}} \leq x_i \leq x_{0i} + \sqrt{d^2 a^{ii}}, \quad i = 1, 2, \dots, p,$$

这里  $a^{ii}$  为  $A^{-1}$  的  $(i, i)$  元素. 围绕  $E_d$  的矩形的边平行于坐标轴.

## 矩阵的导数: 向量关于数量的偏导数

对于向量  $\mathbf{y} = [y_1, y_2, \dots, y_m]^\top$  及数量  $x$ , 定义

$$\frac{\partial \mathbf{y}}{\partial x} = \left[ \frac{\partial y_1}{\partial x}, \frac{\partial y_2}{\partial x}, \dots, \frac{\partial y_m}{\partial x} \right]^\top = \begin{bmatrix} \frac{\partial y_1}{\partial x} \\ \frac{\partial y_2}{\partial x} \\ \vdots \\ \frac{\partial y_m}{\partial x} \end{bmatrix},$$

这是投影  $\mathbb{R} \mapsto \mathbb{R}^m$ .

## 矩阵的导数: 数量关于向量的偏导数

对于数量  $y$  及向量  $\mathbf{x} = [x_1, x_2, \dots, x_n]^\top$ , 定义

$$\frac{\partial y}{\partial \mathbf{x}} = \left[ \frac{\partial y}{\partial x_1}, \frac{\partial y}{\partial x_2}, \dots, \frac{\partial y}{\partial x_n} \right].$$

## 矩阵的导数: 向量关于向量的偏导数

对于向量  $\mathbf{y} = [y_1, y_2, \dots, y_m]^\top$  及向量  $\mathbf{x} = [x_1, x_2, \dots, x_n]^\top$ , 定义

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} & \cdots & \frac{\partial y_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \frac{\partial y_m}{\partial x_2} & \cdots & \frac{\partial y_m}{\partial x_n} \end{bmatrix}.$$

## 矩阵的导数: 矩阵关于数量的偏导数

对于  $m \times n$  矩阵  $\mathbf{y} = \{y_{ij}\}$  及数量  $x$ , 定义

$$\frac{\partial \mathbf{y}}{\partial x} = \begin{bmatrix} \frac{\partial y_{11}}{\partial x} & \frac{\partial y_{12}}{\partial x} & \cdots & \frac{\partial y_{1n}}{\partial x} \\ \frac{\partial y_{21}}{\partial x} & \frac{\partial y_{22}}{\partial x} & \cdots & \frac{\partial y_{2n}}{\partial x} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial y_{m1}}{\partial x} & \frac{\partial y_{m2}}{\partial x} & \cdots & \frac{\partial y_{mn}}{\partial x} \end{bmatrix}.$$



## 矩阵的导数：数量关于矩阵的偏导数

对于数量  $y$  及  $p \times q$  矩阵  $\mathbf{X} = \{x_{ij}\}$ , 定义

$$\frac{\partial y}{\partial \mathbf{X}} = \begin{bmatrix} \frac{\partial y}{\partial x_{11}} & \frac{\partial y}{\partial x_{21}} & \cdots & \frac{\partial y}{\partial x_{p1}} \\ \frac{\partial y}{\partial x_{12}} & \frac{\partial y}{\partial x_{22}} & \cdots & \frac{\partial y}{\partial x_{p2}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial y}{\partial x_{1q}} & \frac{\partial y}{\partial x_{2q}} & \cdots & \frac{\partial y}{\partial x_{pq}} \end{bmatrix}.$$

## 矩阵的导数: 关于内积和二次型的偏导数

考虑向量  $\mathbf{x} = [x_1, x_2, \dots, x_n]^\top$ . 此外, 向量  $\mathbf{a}, \mathbf{b}$  及矩阵  $\mathbf{A}$  不是  $\mathbf{x}$  的函数. 有

$$\frac{\partial \mathbf{a}^\top \mathbf{x}}{\partial \mathbf{x}} = \frac{\partial \mathbf{x} \mathbf{a}^\top}{\partial \mathbf{x}} = \mathbf{a} \text{ 或 } \mathbf{a}^\top;$$

$$\frac{\partial \mathbf{b}^\top \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} = \mathbf{b}^\top \mathbf{A} \text{ 或 } \mathbf{A}^\top \mathbf{b};$$

$$\begin{aligned} \frac{\partial \mathbf{x}^\top \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} &= \mathbf{x}^\top (\mathbf{A} + \mathbf{A}^\top) \text{ 或 } (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}; \\ &= 2\mathbf{x}^\top \mathbf{A} \text{ 或 } 2\mathbf{A} \mathbf{x} \text{ (当 } \mathbf{A} \text{ 对称时);} \end{aligned}$$

$$\frac{\partial \mathbf{x}^\top \mathbf{x}}{\partial \mathbf{x}} = 2\mathbf{x}^\top \text{ 或 } 2\mathbf{x};$$

$$\frac{\partial \mathbf{a}^\top \mathbf{x} \mathbf{x}^\top \mathbf{b}}{\partial \mathbf{x}} = \mathbf{x}^\top (\mathbf{a} \mathbf{b}^\top + \mathbf{b} \mathbf{a}^\top) \text{ 或 } (\mathbf{a} \mathbf{b}^\top + \mathbf{b} \mathbf{a}^\top) \mathbf{x}.$$

## 矩阵的导数: 函数的偏导数

考虑  $f: \mathbb{R}^p \mapsto \mathbb{R}$  和  $p \times 1$  向量  $\mathbf{x}$ , 那么  $\partial f(\mathbf{x})/\partial \mathbf{x}$  为一个偏导数的列向量  $\{\partial f(\mathbf{x})/\partial x_j\} (j = 1, \dots, p)$ , 而  $\partial f(\mathbf{x})/\partial \mathbf{x}^\top$  为同一偏导数的行向量.  $\partial f(\mathbf{x})/\partial \mathbf{x}$  称为  $f$  的梯度.

$\partial^2 f(\mathbf{x})/\partial \mathbf{x} \partial \mathbf{x}^\top$  为二阶导数, 是  $p \times p$  矩阵, 元素为  $\left\{ \frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} \right\} (i = 1, 2, \dots, p; j = 1, 2, \dots, p)$ .  $\partial^2 f(\mathbf{x})/\partial \mathbf{x} \partial \mathbf{x}^\top$  称为  $f$  的 Hessian 矩阵.

二次型  $Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$  的 Hessian 矩阵为:

$$\frac{\partial \mathbf{x}^\top \mathbf{A} \mathbf{x}}{\partial \mathbf{x} \partial \mathbf{x}^\top} = 2\mathbf{A}$$